BioAgent — 生物信息学分析智能体

项目报告

作者：Zeqin Yan **单位**：医疗行业 生物信息分析部门 **日期**：2026年4月 **GitHub**：https://github.com/TLyan-ze/AIgentforme

---

一、单位与工作介绍

1.1 工作背景

所在部门配备高通量测序分析平台、单细胞测序分析平台、生物信息高性能计算集群等设施，承担基础与转化医学研究的技术支撑工作。

1.2 个人工作介绍

日常工作流程包含，从测序公司交付原始数据开始，经过质控、比对、定量、差异分析、功能富集等一系列步骤，最终输出分析报告。主要工作内容包括：

- **RNA-seq 转录组分析**：从表达矩阵出发，使用 DESeq2 进行差异表达分析，GO/KEGG 通路富集分析
- **基因组变异检测**：WES/WGS 数据的变异检测（SNV、InDel），功能影响注释
- **单细胞 RNA-seq 分析**：使用 Seurat/scanpy 进行细胞聚类、标记基因鉴定、细胞类型注释
- **流程搭建与维护**：基于 Snakemake 搭建自动化分析流程

二、有待改进的工作流程

2.1 当前流程：从测序数据到分析报告

测序公司交付数据后，典型的 RNA-seq 分析工作流如下：

```
测序公司交付              人工操作              最终交付

┌──────────┐    ┌──────────────┐    ┌──────────────┐    ┌──────────┐
│ 原始数据  │──>│ 质控 & 比对   │──>│ 差异表达分析   │──>│ 分析报告  │
│ (fastq)  │    │ (已有流程)    │    │ (DESeq2/R)   │    │ (Word)   │
└──────────┘    └──────────────┘    └──────────────┘    └──────────┘
                                          │
                                          ▼
                                   ┌──────────────┐    ┌──────────┐
                                   │ 功能富集分析   │──>│ 整合撰写  │
                                   │ (clusterPr.)  │    │ 分析报告  │
                                   └──────────────┘    └──────────┘
```

当前痛点（以下步骤可由 AI 自动化）：

步骤	当前方式	耗时/次	问题
数据质控统计	手动运行脚本 + 人工整理	15 min	重复性高
差异表达分析	手动写 R 脚本 / 每项目重写	20 min	代码不统一
功能富集分析	手动调用 clusterProfiler	15 min	重复劳动
可视化绑图	每次重写 matplotlib/R 代码	20 min	格式不统一
撰写分析报告	人工阅读结果 + 写 Word	40–60 min	主观性强，质量参差
合计		**110–130 min**	

2.2 工作流程中可使用 LLM/AI 替代的部分

步骤	AI 替代方案	可替代程度
数据质控 → 统计汇总	Python 自动化 + LLM 解读	★★★★★ 完全替代
差异表达分析	DESeq2 (pydeseq2) 封装	★★★★★ 完全替代
GO/KEGG 富集	gseapy 自动化	★★★★★ 完全替代
可视化绑图	封装好的绑图函数	★★★★★ 完全替代
撰写分析报告	LLM 基于结果自动生成	★★★★☆ 大部分替代
生物学解读	LLM 结合知识库	★★★☆☆ 需人工审核

三、智能体设计

3.1 系统架构

```
                    BioAgent 系统架构 (v2.0)

┌──────────────────────────────────────────────────────────────┐
│                          CLI 入口层                          │
│   bio_agent.py rnaseq / variant / scrna / enrich             │
└──────────────────────────────────────────────────────────────┘
                           │
          ┌────────────────┼────────────────┬────────────────┐
          ▼                ▼                ▼                ▼
    ┌──────────┐      ┌──────────┐      ┌──────────┐      ┌──────────┐
    │  Task 1  │      │  Task 2  │      │  Task 3  │      │  Task 4  │
    │  RNA-seq │      │  Variant │      │  scRNA   │      │  Enrich  │
    │  DEG+富集 │      │  变异检测 │      │  单细胞  │      │  功能富集 │
    └──────────┘      └──────────┘      └──────────┘      └──────────┘
          │                │                │                │
          ▼                ▼                ▼                ▼
    ┌──────────────────────────────────────────────────────────┐
    │                     共享分析引擎                          │
    │  DESeq2/pydeseq2 | gseapy | scipy | sklearn              │
    │  matplotlib | seaborn                                    │
    └──────────────────────────────────────────────────────────┘
                           │
                           ▼
                    ┌──────────────┐
                    │  LLM 报告生成 │
                    │ (OpenAI 兼容) │
                    │ 离线模板降级  │
                    └──────────────┘
                           │
                           ▼
                    ┌──────────────┐
                    │ Markdown 报告 │
                    │ PNG 可视化图表 │
                    │ JSON 统计数据 │
                    └──────────────┘
```

3.2 四大任务模块

Task 1: RNA-seq 差异表达 + 功能富集（核心任务）

完整 Pipeline：表达矩阵 → 质控 → DESeq2 → GO/KEGG 富集 → 可视化 → LLM 报告

- **数据输入**：测序公司交付的基因表达矩阵 (CSV) + 样本信息 (CSV)

- **物种支持**：Human (GRCh38) / Mouse (GRCm38)
- **分析步骤**：
- 数据加载与质控（过滤低表达基因）
- DESeq2 差异表达分析（pydeseq2，scipy t-test 降级）
- GO/KEGG 功能富集分析（gseapy/Enrichr）
- 可视化：火山图、样本相关性热图、PCA、Top 基因热图、富集气泡图
- LLM 生成结构化中文分析报告

Task 2: 变异检测报告

- **数据输入**：VCF 文件
- **分析步骤**：解析 VCF → 变异分类统计 → 功能影响注释 → 染色体分布 → AF/DP 分布 → LLM 报告

Task 3: 单细胞 RNA-seq 分析报告

- **数据输入**：标记基因结果 (CSV) + 细胞类型汇总 (CSV)
- **分析步骤**：细胞类型统计 → 标记基因分析 → 共享标记基因 → 热图 → LLM 报告

Task 4: 独立功能富集分析

- **数据输入**：基因列表 (TXT，每行一个基因)
- **分析步骤**：GO/KEGG/Reactome 富集 → 可视化 → LLM 报告

3.3 技术栈

类别	技术
语言	Python 3.8+
差异表达	pydeseq2 (DESeq2) / scipy (降级)
功能富集	gseapy (Enrichr API)
可视化	matplotlib, seaborn
降维	scikit-learn (PCA)
LLM 接口	OpenAI Python SDK (兼容多后端)
数据处理	pandas, numpy

四、实现细节

4.1 代码结构

```
AIgentforme/
├── src/
│   ├── bio_agent.py           # 主入口 CLI (4 个子命令)
│   ├── generate_data.py       # 生成所有任务的模拟数据
│   ├── task_rnaseq.py         # Task 1: 完整 RNA-seq Pipeline
│   ├── task_variant.py        # Task 2: 变异检测报告
│   ├── task_scrna.py          # Task 3: 单细胞分析报告
│   ├── task_enrichment.py     # Task 4: 独立富集分析
│   └── __init__.py
├── data/                      # 示例数据
│   ├── counts_human.csv       # 人类表达矩阵 (3000 基因 × 8 样本)
│   ├── metadata_human.csv     # 人类样本信息
│   ├── counts_mouse.csv       # 小鼠表达矩阵
│   ├── metadata_mouse.csv     # 小鼠样本信息
│   ├── sample_variants.vcf    # 模拟 VCF
│   ├── scrna_markers_*.csv    # 单细胞标记基因
│   ├── scrna_summary_*.csv    # 单细胞细胞类型汇总
│   └── deg_gene_list.txt      # 差异基因列表
├── examples/                  # 示例输出
├── .env.example
├── requirements.txt
├── README.md
└── PROJECT_REPORT.md          # 本文件
```

4.2 Task 1 核心流程详解

```
# 从表达矩阵到报告的完整流程
result = run_pipeline(
    counts_path="data/counts_human.csv",     # 测序公司交付的表达矩阵
    metadata_path="data/metadata_human.csv", # 样本分组信息
    species="human",                         # 支持 human / mouse
    fc_threshold=1.0,                        # log2FC 阈值
    pval_threshold=0.05,                     # padj 阈值
)
# 输出: analysis_report.md + 4张可视化图表 + statistics.json + deg_results.csv
```

Step 1 — 数据加载与质控： – 读取表达矩阵（基因 × 样本）和样本信息（sample_id, condition） – 过滤低表达基因（默认：counts >= 10 且在 >= 2 个样本中）

Step 2 — 差异表达分析： – 优先使用 pydeseq2（DESeq2 的 Python 实现） – 未安装时自动降级为 scipy t-test + BH 校正 – 输出：log2FoldChange, pvalue, padj

Step 3 — 功能富集分析： – 使用 gseapy 调用 Enrichr API – Human: GO_BP_2023 + KEGG_2021_Human – Mouse: GO_BP_2023 + KEGG_2021_Mouse – 未安装 gseapy 或网络不可用时跳过

Step 4 — 可视化： – 火山图（标注 Top 基因） – 样本相关性热图 – PCA 降维图 – Top 差异基因热图 – GO/KEGG 富集条形图

Step 5 — LLM 报告生成： – System Prompt：设定"资深生物信息学分析师"角色 – User Prompt：注入统计数据、Top 基因、富集通路 – Temperature：0.3（确保专业性） – 离线降级：未配置 API 时使用模板生成基本框架

4.3 LLM 集成与降级策略

```
LLM 可用?
  ├── 是 → 调用 OpenAI 兼容 API → 生成完整分析报告
  └── 否 → 使用离线模板 → 生成基本框架 + 统计数据
```

支持所有 OpenAI 兼容后端：OpenAI、DeepSeek、智谱 GLM、通义千问等。

五、项目展示

5.1 使用过程

环境准备

```
git clone https://github.com/TLyan-ze/AIgentforme.git
cd AIgentforme
pip install -r requirements.txt
```

运行各任务

```
# Task 1: RNA-seq 差异表达 + 富集 (人类)
python src/bio_agent.py rnaseq --sample-data --species human

# Task 1: RNA-seq (小鼠)
python src/bio_agent.py rnaseq --sample-data --species mouse

# Task 2: 变异检测
python src/bio_agent.py variant --sample-data

# Task 3: 单细胞
```

```
python src/bio_agent.py scrna --sample-data --species human

# Task 4: 独立富集
python src/bio_agent.py enrich --sample-data
```

查看结果

```
# RNA-seq 输出
ls output/
# analysis_report.md    volcano_plot.png    sample_correlation.png
# pca_plot.png          top_genes_heatmap.png
# deg_results.csv       statistics.json
```

5.2 实验数据与结果

Task 1: RNA-seq 差异表达 + 富集

输入：模拟人类 RNA-seq 表达矩阵（3000 基因 × 8 样本：4 control + 4 treatment）

分析环节	结果
质控	3000 → 2162 基因（过滤 838 低表达）
差异分析	31 个显著差异基因（上调 27，下调 4）
方法	scipy t-test + BH 校正（pydeseq2 可选）
可视化	火山图、相关性热图、PCA、Top 基因热图
报告	analysis_report.md

可视化输出：- `volcano_plot.png`：火山图，标注 Top 差异基因 - `sample_correlation.png`：样本相关性热图，验证分组合理性 - `pca_plot.png`：PCA 降维图，展示样本聚类 - `top_genes_heatmap.png`：Top 30 差异基因表达热图

Task 2: 变异检测

输入：模拟 VCF 文件（500 个变异位点）

指标	值
总变异数	500
SNV	332

指标	值
InDel	168
HIGH impact	变异功能分级统计
可视化	变异类型分布、染色体分布、AF/DP 分布

Task 3: 单细胞分析

输入：模拟标记基因（106 条）+ 8 种细胞类型

指标	值
细胞类型	8 种
总细胞数	15,991
标记基因	106 条
可视化	细胞分布、标记基因热图

5.3 使用效果评估

效率对比

指标	人工流程	BioAgent	提升幅度
数据质控	15 min	< 1s	~900x
差异分析	20 min	~1s	~1200x
功能富集	15 min	~2s (网络)	~450x
可视化	20 min	~3s	~400x
报告撰写	40–60 min	5–15s (LLM)	~240x
总计	**110–130 min**	**< 30s**	**~250x**

测试结果

测试场景	状态	耗时
RNA-seq (human, 离线模式)	通过	~1.3s

测试场景	状态	耗时
RNA-seq (mouse, 离线模式)	通过	~1.3s
Variant Calling	通过	~0.2s
scRNA-seq (human)	通过	~0.2s
Enrichment (需网络)	通过 (需 gseapy)	~5-10s

六、讨论与展望

6.1 优势

1. **覆盖完整工作流**：从测序公司交付数据到分析报告，一站式完成
2. **多任务支持**：差异表达、变异检测、单细胞、功能富集四大类分析
3. **物种支持**：Human / Mouse 双物种
4. **LLM 增强**：大语言模型自动撰写专业分析报告
5. **降级策略**：pydeseq2 → scipy，gseapy → 跳过，LLM → 离线模板，层层保障
6. **易于集成**：CLI 设计，可嵌入 Snakemake / Nextflow 等流程框架

6.2 局限性

1. pydeseq2 的 Python 实现与 R 版 DESeq2 存在细微差异
2. gseapy 富集分析依赖网络连接
3. LLM 可能产生幻觉，生成的生物学解读需人工审核
4. 当前单细胞任务基于预处理后的标记基因，未包含上游聚类分析

6.3 后续改进方向

1. **pydeseq2 集成优化**：确保与 R DESeq2 结果的一致性
2. **多格式输出**：支持 Word (.docx) 和 PDF
3. **交互式报告**：Plotly/Dash 生成交互式 HTML 报告
4. **RAG 增强**：构建本地文献知识库，提升 LLM 解读准确性
5. **流程编排**：与 Snakemake 深度集成，从 fastq 到报告的全自动流程

七、总结

本项目基于我在医疗行业的实际工作需求，设计并实现了 BioAgent——一个多任务生物信息学分析智能体。该智能体覆盖了 RNA-seq 差异表达分析（从表达矩阵到报告）、变异检测、单细胞分析、功能富集分析四大核心任务，将整个分析报告生成流程从 2 小时缩短至分钟级，有效提升了工作效率和分析质量的一致性。

Zeqin Yan — 医疗行业 生物信息工程师 2026年4月